

Metodi Statistici per la Neuropsicologia Forense

4c. Affidabilità - Formule

Giorgio Arcara,
Università di Padova
IRCCS San Camillo, Venezia



4c. Affidabilità - Formule

Gli *Standards for Educational and Psychological Testing* (AERA, APA, & NCME, 2014) trattano l'affidabilità come un **principio unitario** (termine ombrello: *affidabilità/precisione*): non un'unica proprietà, ma un insieme di stime di precisione, ciascuna specifica a una **fonte di errore**.

- Affidabilità test-retest
- Consistenza interna (e affidabilità split-half)
- Inter-rater agreement

La terminologia è quella della Teoria Classica dei Test (il modello dominante per i test neuropsicologici); *Generalizability Theory* e *Item Response Theory* usano termini diversi. Per le classificazioni: Urbina, 2004.

Quanto deve essere alta l'affidabilità?

Non esistono soglie universali. Riferimento orientativo, valido per tutti i tipi di affidabilità (Slick, cap. 1 in Spreen & Strauss, 2006):

Coefficiente	Interpretazione
≥ 0.90	molto alta
0.80 – 0.89	alta
0.70 – 0.79	adeguata
0.60 – 0.69	marginale
< 0.60	bassa

Per le **decisioni cliniche sul singolo individuo** Sattler (2001) raccomanda soglie più stringenti: ≥ 0.80 ; per decisioni ad alto impatto (es. QI, diagnosi) 0.90 è il minimo, 0.95 l'ottimale. In pratica: approccio *comparativo* (scegliere il test con affidabilità migliore).

Affidabilità test-retest

Affidabilità test-retest: consistenza dei punteggi quando lo stesso test è somministrato alle stesse persone in due momenti diversi, assumendo che nell'intervallo non ci siano stati cambiamenti reali nel costrutto.

Una formula molto diffusa (specie nei test in Italiano) è la correlazione di *Pearson*:

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

x_i, y_i = punteggi al test e al retest

$\bar{x}, \bar{y}$ = medie dei punteggi al test e al retest

Affidabilità test-retest ed effetti sistematici

Il coefficiente di correlazione esprime la *consistenza relativa* tra le due misurazioni (quanto le persone mantengono lo stesso ordinamento), ma non cattura eventuali *effetti sistematici* di differenza tra i punteggi: può essere molto alto anche quando i punteggi al retest sono sistematicamente più alti.

Definiamo *effetto sistematico* una variazione non casuale nei punteggi tra test e retest presente in ogni individuo (es. effetto pratica).

Per questo, quando l'affidabilità test-retest è espressa con una correlazione, il coefficiente andrebbe accompagnato dall'analisi dei cambiamenti sistematici (es. confronto tra le medie, distribuzione delle differenze; es. Arcara & Bambini, 2016).

Affidabilità test-retest (correlazione)

Immaginiamo un caso in cui ad ogni osservazione si aggiunga una quantità fissa k . Conseguirà che anche la media sarà aumentata di k :

$$r = \frac{\sum (x_i - \bar{x})(y_i + k - (\bar{y} + k))}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i + k - (\bar{y} + k))^2}}$$

Segue da semplice algebra che le k si cancellano e quindi si ritorna alla formula iniziale: un aumento sistematico non cambia il valore della correlazione (vedi anche slides su Correlazione nell'Appendice concetti base di statistica)

Nei test cognitivi l'effetto sistematico più comune è riconducibile all'effetto pratica, l'etichetta utilizzata per indicare quei cambiamenti (spesso sistematici) che si osservano nella somministrazione del test e che sono associati ad una migliore performance.

Attenzione dunque all'utilizzo e all'interpretazione dei valori di test-retest reliability se misurata tramite correlazione.

Se usata la correlazione, sarebbe infatti necessario accompagnarla con analisi (es. t-tests) che permettano di vedere se c'è una differenza sistematica tra prima e seconda valutazione.

Considerazioni su affidabilità test-retest

Spesso l'affidabilità test-retest viene (erroneamente) considerata utile solo nel caso in cui avvengano misurazioni ripetute.

Dobbiamo invece immaginare una valutazione come una fotografia di una scena statica. La affidabilità test-retest stima quanto è precisa la vostra macchina fotografica.

In un test ad elevata affidabilità, non ci aspettiamo tante possibili variazioni, invece in un test con bassa affidabilità ci aspettiamo molte variazioni.


La nostra fotografia sarà una stima “puntuale”, ma potrebbe essere lontana da quella che consideriamo il punteggio vero (che ricordiamo è un'entità teorica).

Considerazioni su affidabilità test-retest

Nella slide successiva si mostra questo concetto, ipotizzando delle singole misurazioni m_a ed m_b in due test (uno a bassa affidabilità test-retest e uno ad alta affidabilità test-retest).

Per ogni test verrà fatta una sola valutazione e non c'è interesse nella rivalutazione nel tempo. Nel test con alta affidabilità test-retest, avremo un punteggio osservato che è meno dipendente dalla specifica istanza di misurazione.

Affidabilità test-retest



Test bassa affidabilità test-retest

Test alta affidabilità test-retest

Perché viene spesso usato il coefficiente di correlazione di Pearson (r) se non è adeguato?

Probabilmente per semplice convenzione e per semplicità (il coefficiente r di pearson può esprimere facilmente la varianza condivisa tra le variabili, semplicemente calcolando r^2).

Non è completamente sbagliato e può fornire un quadro abbastanza completo se accompagnato da t-tests (per indagare differenze sistematiche).

Affidabilità test-retest

Esistono diversi modi di misurare l'affidabilità test-retest e sempre più spesso si usano formule più appropriate, in particolare l'**Intraclass Correlation (ICC)** basata sull'*accordo assoluto*, che tiene conto anche degli effetti sistematici (le formule della ICC saranno trattate per l'inter-rater agreement).

Nel tipico disegno test-retest (due occasioni prestabilite, uguali per tutti) si raccomanda un modello ICC a due vie, a effetti misti, basato sull'accordo assoluto e riferito a una singola misurazione — spesso indicato come ICC(2,1) o ICC(A,1) (Shrout & Fleiss, 1979; McGraw & Wong, 1996; Koo & Li, 2016).

Soglie indicative: ≥ 0.70 per ricerca/confronti tra gruppi; per decisioni sul singolo individuo spesso ≥ 0.90 , idealmente ~ 0.95 (Nunnally & Bernstein, 1994).

Inter-rater agreement

Inter-rater agreement

Inter-rater agreement (o *affidabilità inter-rater*): quanto è consistente il punteggio assegnato da valutatori diversi che osservano la stessa prestazione. È praticamente per definizione legato all'*oggettività* del test (l'indipendenza del risultato dall'osservatore).

È tendenzialmente più basso nei test in cui la risposta non è univoca o è graduata (es. disegno, descrizione, interpretazione di proverbi), più alto quando la risposta corretta è univoca e dicotomica (es. digit span). Al di là della complessità del comportamento, l'elemento cruciale e trasversale è la **chiarezza delle regole di attribuzione dei punteggi**, comprese le indicazioni per i casi ambigui.

Inter-rater agreement

La formula più utilizzata è l'**Intraclass Correlation (ICC)**. A differenza della correlazione (solo 2 variabili), l'ICC può essere usata per k raters.

L'ICC non è un singolo coefficiente ma una **famiglia** di coefficienti, che assumono relazioni diverse tra gruppi e osservazioni e si basano su scomposizione della varianza (ANOVA / mixed-effects). Per l'inter-rater agreement sono rilevanti le ICC basate sull'**accordo assoluto** (valori alti solo se i raters assegnano più o meno lo stesso punteggio, non solo se i punteggi sono correlati).

https://en.wikipedia.org/wiki/Intraclass_correlation

Inter-rater agreement

Una versione spesso utilizzata è la **ICC(2,1) agreement**: si assume che diversi rater vedano la stessa prestazione dello stesso soggetto e si ottiene una stima dell'agreement in termini assoluti.


$$ICC(2,1) = \frac{MSB - MSE}{MSB + (n_j - 1)MSE + \frac{n_j(MSJ - MSE)}{n_c}}$$

MSB, MSJ = varianza tra soggetti, tra giudici (rater)

MSE = varianza dell'interazione giudici $\times$ soggetti

n_c, n_j = numero di giudici, di casi

Inter-rater agreement



La figura mostra come diverse relazioni sono catturate da diversi coefficienti.

Nota che R^2 è il coefficiente di correlazione r elevato al quadrato, ma è anche usato nelle regressioni (in breve altre analisi statistiche dove si indaga la relazione tra variabili usando equazione del tipo $y = bx + e$).

a

^aDa pagina Wikipedia Intraclass Correlation

Perché non è sempre usata ICC anche per test-retest visto che tiene conto anche di differenze sistematiche?

Probabilmente per prassi e convenzione (che si osserva soprattutto nei test in Italiano). In letteratura è però possibile trovare alcuni studi che la utilizzano anche per test-retest e nel corso degli anni sempre più autori seguono la più appropriata formula di ICC. In caso di effetto pratica sarebbe infatti più adeguata.

Soglie indicative per l'inter-rater agreement (ICC): < 0.40 scarso, $0.40 - 0.59$ discreto, $0.60 - 0.74$ buono, ≥ 0.75 eccellente (Cicchetti & Sparrow, 1981); con classificazione simile, Fastenau et al. (1996) considerano 0.60 la soglia per un accordo “sostanziale” e $0.75 - 0.80$ per uno “quasi perfetto”.

Consistenza interna (e split-half)

Affidabilità split-half

Un approccio tradizionale per calcolare la consistenza degli item di un test è dividere in due il test (tipicamente item pari da un lato, dispari dall'altro) e calcolare la correlazione tra i punteggi delle due metà nei vari partecipanti. **Questo metodo è detto split-half reliability (o affidabilità split-half).**

Poiché ciascuna metà è più corta dell'intero test, la correlazione tra le due metà **sottostima** l'affidabilità del test completo: si applica quindi la correzione di **Spearman-Brown**.

Limite principale: il risultato dipende, almeno in parte, da come si divide il test. Per questo si preferisce la sua estensione, la *consistenza interna*. *Soglia indicativa:* $\geq 0.70 - 0.80$ (Slick, 2006).

Consistenza interna: rappresenta quanto gli item di un test siano tra loro coerenti, cioè quanto misurino (almeno in parte) la stessa cosa.

Concettualmente stima quale sarebbe la correlazione media considerando *tutte* le possibili divisioni split-half. È un concetto a cavallo tra affidabilità e validità (struttura fattoriale del test).

Formula di Kuder-Richardson (K-R 20)

È una formula che viene usata quando gli item sono dicotomici (0/1)

$$r_{KR20} = \left(\frac{n}{n-1} \right) \frac{s_t^2 - \sum pq}{s_t^2}$$

n = numero di items nel test

s_t^2 = varianza del punteggio totale nel test

$\sum pq$ = somma del prodotto $p \times q$ in ogni item del test

p = proporzione delle persone che passano l'item (o risposta 1)

q = proporzione delle persone che non passano l'item (o risposta 0)

Cronbach's alpha

È l'indice più diffuso, una generalizzazione della formula KR-20 al caso di item non dicotomici

$$\alpha = \left(\frac{n}{n-1} \right) \frac{s_t^2 - \sum s_i^2}{s_t^2}$$

n = numero di items nel test

s_t^2 = varianza del punteggio totale nel test

s_i^2 = varianza di ogni item al test

α è un *limite inferiore* dell'affidabilità e assume item (essenzialmente) tau-equivalenti e unidimensionali.

Altri metodi per calcolare la consistenza interna

Sebbene KR-20 e α siano i più comuni, hanno limiti intrinseci (es. assumono unidimensionalità).

- **omega di McDonald (ω)**: alternativa più recente e considerata **più robusta**, adatta anche in caso di multidimensionalità; oggi spesso raccomandata come default.
- **GLB (Greatest Lower Bound)**: preferibile se i punteggi degli item non sono normali.

ω e GLB sono legati alle analisi fattoriali (vedi slides su validità) e computazionalmente più complessi. Per i **test di velocità** la consistenza interna non è una misura appropriata.

Soglie indicative: < 0.70 inaccettabile, $0.70 - 0.79$ discreto, $0.80 - 0.89$ buono, ≥ 0.90 eccellente (Slick, 2006); nei test neuropsicologici spesso ~ 0.60 .

Item selection

Un concetto associato a KR-20, Cronbach's alpha, e altre misure di consistenza interna è quello dell'item selection e cioè quella procedura nella creazione di un test di identificazione degli item da mantenere nel test finale.

Alcune misure sono specifiche per items (un po' come I loadings nell'analisi fattoriale).

Esempi che vengono dall'alpha di Cronbach:

- **r-drop**: indica la correlazione tra il test, e il test tolto quell'item (si ha dunque un valore r-drop per item)
- **r-cor**: indica la correlazione tra l'item e il test totale controllando per overlap con altri item e per affidabilità globale.

Interpretare l'affidabilità a livello del test

Ogni sorgente di affidabilità può essere usata per stimare l'errore di misura del test.

Il coefficiente di affidabilità (indipendente dalla formula) può infatti essere interpretato come la percentuale di variabilità riconducibile al punteggio vero, trasformando semplicemente il coefficiente in percentuale. Questo segue la definizione che viene fatta a priori di cosa è l'affidabilità.

Ad esempio:

Una correlazione test-retest 0.8 vuol dire che l'80% di variabilità test-retest è riconducibile alla variabilità del punteggio vero.

Una consistenza interna di 0.9 vuol dire che il 90% di variabilità nella consistenza interna è riconducibile alla variabilità del punteggio vero, etc.

Interpretare l'affidabilità a livello del test

L'errore associato ad ogni sorgente di affidabilità è pertanto calcolabile come:

$$Errore = (1 - C_a) \times 100$$

Dove C_a è il coefficiente di affidabilità in questione (es. Affidabilità test retest, affidabilità inter rater, etc).

Combinare diversi tipi di errore

Calcolando diverse sorgenti di errore è possibile sommarle (assumendo la loro indipendenza) per ottenere un errore totale e calcolare quindi la variabilità del punteggio che si presume sia riconducibile al punteggio vero

Es. supponiamo di avere un test che ha le seguenti caratteristiche:

- Affidabilità test-retest = 0.85 (r di pearson)
- Affidabilità inter-rater = 0.70 ($ICC(2, 1)$)
- Consistenza interna = 0.97 (alpha di Cronbach)

Combinare diversi tipi di errore

Errore test-retest: $(1 - 0.85) \times 100 = 15\%$

Errore inter-rater: $(1 - 0.7) \times 100 = 30\%$

Errore consistenza interna: $(1 - 0.97) \times 100 = 3\%$

Errore totale: $15 + 30 + 3 = 48\%$

A livello di test il 48% della varianza è riconducibile ad errore, e il 52% ($100 - 48$) al punteggio vero (che è anche l'affidabilità complessiva del test). (Vedi Urbina, 2004, per un esempio simile)

Attenzione: questa scomposizione additiva assume che le sorgenti di errore siano *indipendenti* ed è un artificio grossolano. Nella pratica psicometrica la precisione complessiva è espressa più propriamente tramite l'errore standard di misurazione (*SEM*) e i relativi intervalli di confidenza (non approfonditi qui).

Stimare il punteggio vero

Le formule di affidabilità ci permettono inoltre di stimare il punteggio vero

$$T' = r_{xx}(X - M) + M$$

T' = stima del punteggio vero

r_{xx} = affidabilità complessiva (vedi slide precedente)

X = punteggio osservato

M = media del campione di riferimento

Stimare il punteggio vero: alcune note

- 1) La stima del punteggio vero è spesso accompagnata anche dalla creazione di intervalli di confidenza attorno alla stima (riprenderemo questo quando parleremo di cut-offs, vedi anche Appendice)

Nota che nell'approccio prima descritto (di stimare l'affidabilità globale a partire dalle diverse affidabilità), più informazioni abbiamo più bassa sarà la percentuale riconducibile alla varianza del punteggio vero.

Un altro modo per pensare il problema è che stimare la varianza riconducibile a punteggio vero a partire da un solo indice sarà inevitabilmente una sovrastima della stessa.

Stimare il punteggio vero: alcune note

- 2) Per stimare il punteggio vero entra due volte in gioco la media del campione di riferimento (denotata con M). Questo permette di tenere in considerazione un fenomeno detto **regressione verso la media**: in ogni misura con errore è sempre più probabile che una misura successiva sia più vicina alla media del campione di riferimento. Questo perché, specie se l'errore dello strumento è grande, ogni deviazione della media ha probabilità di essere dovuta al caso.

Correggere per la media ha però un grosso limite intrinseco: con che media correggere? Ad esempio, se ho un paziente con TBI è corretto usare (per M), la media del gruppo di sani con cui è stato sviluppato il test?

Stimare il punteggio vero: alcune note

Questo tipo di limiti rende complessa l'applicazione di formule per stimare il punteggio vero. Vedremo in futuro comunque in utilizzi clinici e pratici (es. cut-off, valori di cambiamento), **quasi sempre non sono usati i punteggi veri ma i punteggi osservati.**

Come considerare i coefficienti di affidabilità

Ogni coefficiente di affidabilità, in generale, stima la varianza riconducibile al punteggio vero rispetto alla variabilità totale (cioè quella che si rileva nei punteggi osservati), utilizzando diverse formule (es. r di Pearson, $ICC(2, 1)$, etc.).

L'idea generale può essere espressa da questa formula.

$$r_{xx} = \frac{\sigma_{true}}{\sigma_{tot}}$$

Riferimenti

- AERA, APA, & NCME (2014). *Standards for Educational and Psychological Testing*.
- Cicchetti, D. V., & Sparrow, S. A. (1981). *American Journal of Mental Deficiency*.
- Fastenau, P. S., et al. (1996).
- Koo, T. K., & Li, M. Y. (2016). *Journal of Chiropractic Medicine*.
- McGraw, K. O., & Wong, S. P. (1996). *Psychological Methods*.
- Nunnally, J. C., & Bernstein, I. H. (1994). *Psychometric Theory* (3rd ed.).
- Sattler, J. M. (2001). *Assessment of Children*.
- Shrout, P. E., & Fleiss, J. L. (1979). *Psychological Bulletin*.
- Slick, D. J. (2006). Psychometrics in neuropsychological assessment. In Spreen & Strauss (cap. 1).
- Urbina, S. (2004). *Essentials of Psychological Testing*.