

Metodi Statistici per la Neuropsicologia Forense

4c. Affidabilità - Formule

Giorgio Arcara,
Università di Padova
IRCCS San Camillo, Venezia



4c. Affidabilità - Formule

Tipi di affidabilità

- Affidabilità test-retest
- Affidabilità inter-rater
- Affidabilità split-half
- Consistenza interna

Esistono diverse classificazioni di affidabilità. Questa è principalmente basata su Urbina, 2004, Essentials of Psychological Testing.

Affidabilità test-retest

Affidabilità test-retest

Affidabilità test-retest: è un indice che rappresenta la consistenza nel tempo di due misurazioni assumendo che non è avvenuto nessun cambiamento sistematico.

Una formula molto diffusa per calcolare affidabilità test-retest, soprattutto nei test sviluppati in Italiano, è quella della correlazione di *Pearson* (vedi anche l'Appendice di queste slides):

$$r = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2}}$$

r = correlation coefficient

x_i = values of the x-variable in a sample

$\bar{x}$ = mean of the values of the x-variable

y_i = values of the y-variable in a sample

$\bar{y}$ = mean of the values of the y-variable

Il più grande problema dell'affidabilità test-retest quando misurata tramite coefficiente di correlazione è che essa non cattura eventuali *effetti sistematici* di differenza tra i punteggi. Il valore infatti ci dice quanto due valori sono correlati o consistenti, ma non se sono più o meno gli stessi.

Definiamo *effetto sistematico* una variazione non casuale nei punteggi tra test e retest presente in ogni individuo (es. effetto pratica)

Affidabilità test-retest (correlazione)

Immaginiamo un caso in cui ad ogni osservazione si aggiunga una quantità fissa k . Conseguirà che anche la media sarà aumentata di k :

$$r = \frac{\sum (x_i - \bar{x})(y_i + k - (\bar{y} + k))}{\sqrt{\sum (x_i - \bar{x})^2 \sum (y_i + k - (\bar{y} + k))^2}}$$

Segue da semplice algebra che le k si cancellano e quindi si ritorna alla formula iniziale: un aumento sistematico non cambia il valore della correlazione (vedi anche slides su Correlazione nell'Appendice concetti base di statistica)

Nei test cognitivi l'effetto sistematico più comune è riconducibile all'effetto pratica, l'etichetta utilizzata per indigare quei cambiamenti (spesso sistematici) che si osservano nella somministrazione del test e che sono associati ad una migliore performance.

Attenzione dunque all'utilizzo e all'interpretazione dei valori di test-retest reliability se misurata tramite correlazione.

Se usata correlazione, sarebbe infatti necessario accompagnare da analisi (es. t-tests) che permettano di vedere se c'è una differenza sistematica tra prima e seconda valutazione.

Considerazioni su affidabilità test-retest

Spesso l'affidabilità test-retest viene (erroneamente) considerata utile solo nel caso in cui avvengano misurazioni ripetute.

Dobbiamo invece immaginare una valutazione come una fotografia di una scena statica. La affidabilità test-retest stima quanto è precisa la vostra macchina fotografica.

In un test ad elevata affidabilità, non ci aspettiamo tante possibili variazioni, invece in un test con bassa affidabilità ci aspettiamo molte variazioni.


La nostra fotografia sarà una stima “puntuale”, ma potrebbe essere lontana da quella che consideriamo il punteggio vero (che ricordiamo è un'entità teorica).

Considerazioni su affidabilità test-retest

Nella slide successiva si mostra questo concetto, ipotizzando delle singole misurazioni m_a ed m_b in due test (uno a bassa affidabilità test-retest e uno ad alta affidabilità test-retest).

Per ogni test verrà fatta una sola valutazione e non c'è interesse nella rivalutazione nel tempo. Nel test con alta affidabilità test-retest, avremo un punteggio osservato che è meno dipendente dalla specifica istanza di misurazione.

Affidabilità test-retest



Test bassa affidabilità test-retest

Test alta affidabilità test-retest

Perché viene spesso usato il coefficiente di correlazione di Pearson (r) se non è adeguato?

Probabilmente per semplice convenzione e per semplicità (il coefficiente r di pearson può esprimere facilmente la varianza condivisa tra le variabili, semplicemente calcolando r^2).

Non è completamente sbagliato e può fornire un quadro abbastanza completo se accompagnato da t-tests (per indagare differenze sistematiche).

Esistono però diversi modi di misurare affidabilità test-retest e sempre più di recente, sono però utilizzate formule più appropriate (es. quelle di Intraclass correlation che saranno trattate per affidabilità inter-rater)

Affidabilità inter-rater

Affidabilità inter-rater

Affidabilità inter-rater: è un'indice che rappresenta la coerenza dei punteggi di più rater.

La formula più utilizzata per l'affidabilità inter-rater è l'**Intra Class Correlation (ICC)**.

A differenza della correlazione (che può essere usata solo per 2 variabili), l'ICC invece può essere usata per k variabili (dove k è il numero di rater).

Esistono diverse formule di Intraclass correlation, che sostanzialmente rispondono a diverse domande e che assumono una diversa relazione tra gruppi e osservazioni (nel nostro caso rater e pazienti osservati). Le formule più recenti per intraclass correlation si basano su scomposizione di varianza fatta tramite ANOVA o tramite mixed effect models (utile da sapere ma non approfondiamo).

https://en.wikipedia.org/wiki/Intraclass_correlation

Affidabilità inter-rater

La versione di ICC più utilizzata per calcolare l'affidabilità inter-rater è la **ICC(2,1) agreement**.

Nel contesto di test con questa versione di ICC si assume che più rater vedano la stessa prestazione dello stesso soggetto e fornisce una stima che tiene conto dell'agreement in termini assoluti (se il punteggio è lo stesso, non se il punteggio è correlato).

$$ICC(2,1) = \frac{(MSB - MSE)}{(MSB + (n_j - 1)MSE + \frac{n_j(MSJ - MSE)}{n_c})}$$

MSB = variance between subjects


MSJ = variance between judges (raters)

MSE = variance of interaction judges by subjects

n_c = number of judges (raters)

n_j = number of cases (observations)

Affidabilità inter-rater



a

^aDa pagina Wikipedia Intraclass Correlation

La figura mostra come diverse relazioni sono catturate da diversi coefficienti.

Nota che R^2 è il coefficiente di correlazione r elevato al quadrato, ma è anche usato nelle regressioni (in breve altre analisi statistiche dove si indaga la relazione tra variabili usando equazione del tipo $y = bx + e$).

Perché non è sempre usata ICC anche per test-retest visto che tiene conto anche di differenze sistematiche?

Probabilmente per prassi e convenzione (che si osserva soprattutto nei test in Italiano). In letteratura è però possibile trovare alcuni studi che la utilizzano anche per test-retest e nel corso degli anni sempre più seguono la più appropriata formula di ICC. In caso di effetto pratica sarebbe infatti più adeguata.

Affidabilità split-half

Un approccio tradizionale per calcolare la consistenza di item di un test, è quella di dividere in due il test e indagare misure di somiglianza (es. correlazione) tra i punteggi delle due metà nei vari partecipanti. **Questo metodo è detto split-half reliability (o affidabilità split-half).**

Il grosso limite di questo approccio è che il risultato dipende da come dividiamo a metà il test (potremmo sovrastimare o sottostimare).

Consistenza interna

Consistenza interna: rappresenta la consistenza tra gli item di un test.

Da un punto di vista concettuale le misure di consistenza interna vanno ad indagare invece quale sarebbe la correlazione usando tutte le possibili divisioni split-half.

Formula di Kuder-Richardson (K-R 20)

È una formula che viene usata quando gli item sono dicotomici (0/1)

$$r_k - R20 = \left(\frac{n}{n-1}\right) \frac{s_t^2 - \sum pq}{s_t^2}$$

n = numero di items nel test

s_t^2 = varianza del punteggio totale nel test

$\sum pq$ = somma del prodotto $p \times q$ in ogni item del test

p = proporzione delle persone che passano l'item (o risposta 1)

q = proporzione delle persone che non passano l'item (o risposta 0)

Cronbach's alpha

È una generalizzazione della formula KR-20, nel caso di items non dicotomici

$$\alpha = \left(\frac{n}{n-1} \right) \frac{s_t^2 - \sum s_i^2}{s_t^2}$$

n = numero di items nel test

s_t^2 = varianza del punteggio totale nel test

s_i^2 = varianza di ogni item al test

Altri metodi per calcolare la consistenza interna

Anche se i metodi KR-20 e alpha sono i più comuni essi hanno dei limiti intrinseci (Es. Assumono unidimensionalità).

In alcuni quindi da preferire altri metodi. Esempio: se i punteggi degli item non sono normali meglio il metodo **GLB (Greatest Lower Bound)**.

In caso di multidimensionalità può essere meglio usare il metodo **omega (ω)**.

Nota che GLB e omega sono legati ad analisi fattoriali (vedi slides su validità) e sono computazionalmente più complessi.

Item selection

Un concetto associato a KR-20, Cronbach's alpha, e altre misure di consistenza interna è quello dell'item selection e cioè quella procedura nella creazione di un test di identificazione degli item da mantenere nel test finale.

Alcune misure sono specifiche per items (un po' come I loadings nell'analisi fattoriale).

Esempi che vengono dall'alpha di Cronbach:

- **r-drop**: indica la correlazione tra il test, e il test tolto quell'item (si ha dunque un valore r-drop per item)
- **r-cor**: indica la correlazione tra l'item e il test totale controllando per overlap con altri item e per affidabilità globale.

Interpretare l'affidabilità a livello del test

Ogni sorgente di affidabilità può essere usata per stimare l'errore di misura del test.

Il coefficiente di affidabilità (indipendente dalla formula) può infatti essere interpretato come la percentuale di variabilità riconducibile al punteggio vero, trasformando semplicemente il coefficiente in percentuale. Questo segue la definizione che viene fatta a priori di cosa è l'affidabilità.

Ad esempio:

Una correlazione test-retest 0.8, vuol dire che 80% di variabilità test-retest è riconducibile alla variabilità del punteggio vero.

Una consistenza interna di 0.9, vuol dire che 90% di variabilità nella consistenza interna pè riconducibile alla variabilità del punteggio vero, etc.

Interpretare l'affidabilità a livello del test

L'errore associato ad ogni sorgente di affidabilità è pertanto calcolabile come:

$$Errore = (1 - C_a) * 100$$

Dove C_a è il coefficiente di affidabilità in questione (es. Affidabilità test retest, affidabilità inter rater, etc).

Combinare diversi tipi di errore

Calcolando diverse sorgenti di errore è possibile sommarle (assumendo la loro indipendenza) per ottenere un errore totale e calcolare quindi la variabilità del punteggio che si presume sia riconducibile al punteggio vero

Es. supponiamo di avere un test che ha le seguenti caratteristiche:

- Affidabilità test-retest = 0.85 (r di pearson)
- Affidabilità inter-rater = 0.70 ($ICC(2, 1)$)
- Consistenza interna = 0.97 (alpha di Cronbach)

Combinare diversi tipi di errore

Errore test-retest: $(1 - 0.85) * 100 = 15$

Errore inter-rater: $(1 - 0.7) * 100 = 30$

Errore consistenza interna: $(1 - 0.97) * 100 = 3$

Errore totale: $15 + 30 + 3 = 48$

A livello di test il 48% della varianza è riconducibile ad errore, e il 52% ($100 - 48$) della varianza è riconducibile al punteggio vero (è anche l'affidabilità complessiva del test). (Vedi Urbina, 2004, per esempio simile)

Stimare il punteggio vero

Le formule di affidabilità ci permettono inoltre di stimare il punteggio vero

$$T' = r_{xx}(X - M) + M$$

T' = stima del punteggio vero

r_{xx} = affidabilità complessiva (vedi slide precedente)

X = punteggio osservato

M = media del campione di riferimento

- 1) La stima del punteggio vero è spesso accompagnata anche dalla creazione di intervalli di confidenza attorno alla stima (riprenderemo questo quando parleremo di cut-offs, vedi anche Appendice)

Nota che nell'approccio prima descritto (di stimare l'affidabilità globale a partire dalle diverse affidabilità), più informazioni abbiamo più bassa sarà la percentuale riconducibile alla varianza del punteggio vero.

Un altro modo per pensare il problema è che stimare la varianza riconducibile a punteggio vero a partire da un solo indice sarà inevitabilmente una sovrastima della stessa.

Stimare il punteggio vero: alcune note

- 2) Per stimare il punteggio vero entra due volte in gioco la media del campione di riferimento (denotata con M). Questo permette di tenere in considerazione un fenomeno detto **regressione verso la media**: in ogni misura con errore è sempre più probabile che una misura successiva sia più vicina alla media del campione di riferimento. Questo perché, specie se l'errore dello strumento è grande, ogni deviazione della media ha probabilità di essere dovuta al caso.

Correggere per la media ha però un grosso limite intrinseco: con che media correggere? Ad esempio, se ho un paziente con TBI è corretto usare (per M), la media del gruppo di sani con cui è stato sviluppato il test?

Stimare il punteggio vero: alcune note

Questo tipo di limiti rende complessa l'applicazione di formule per stimare il punteggio vero. Vedremo in futuro comunque in utilizzi clinici e pratici (es. cut-off, valori di cambiamento), **quasi sempre non sono usati i punteggi veri ma i punteggi osservati.**

Come considerare i coefficienti di affidabilità

Ogni coefficiente di affidabilità, in generale stimare la varianza riconducibile al punteggio vero, rispetto alla variabilità totale (cioè quella che si rileva nei osservati), utilizzando diverse formule (es. r di pearson, $ICC(2, 1)$, etc.).

L'idea generale può essere espressa da questa formula.

$$r_{xx} = \frac{\sigma_{true}}{\sigma_{tot}}$$