Validità: formule e analisi

Handout della lezione 3b — Metodi Statistici per la Neuropsicologia Forense

Giorgio Arcara

> **Nota sull'uso dell'intelligenza artificiale**
>
> Questo handout è stato generato con l'assistenza di **Claude** (Anthropic), un modello di intelligenza artificiale, a partire dalle slide della lezione 3b (*Validità – formule*). Al modello è stato chiesto di riscrivere in forma discorsiva il contenuto delle slide, integrandone le figure, **senza aggiungere nuovo materiale**. Il testo può comunque contenere imprecisioni: in caso di dubbio fanno fede le slide e quanto detto a lezione.
> Materiale distribuito con licenza CC BY-NC 3.0, come le slide del corso.

1 Tipi di validità

Il libro di riferimento del corso, *Oltre i punteggi* (Arcara, 2025), adotta la cornice degli *Standards for Educational and Psychological Testing* (American Educational Research Association, American Psychological Association, & National Council on Measurement in Education, 2014), secondo cui la validità è un **concetto unitario**, valutato attraverso cinque fonti di evidenza. In questo handout vediamo la versione quantitativa delle etichette classiche più diffuse: la validità di contenuto, la validità convergente/divergente (cioè la validità di costrutto), la validità di criterio e la validità ecologica. A queste si aggiunge la validità di facciata, che però è un concetto storico e viene trattata a parte.

Conviene leggere queste etichette come una sequenza di domande diverse rivolte allo stesso test. La **validità di contenuto** chiede se, secondo gli esperti, gli item sono adeguati a valutare il costrutto. La **validità di costrutto** chiede se, nei dati, gli item e il punteggio totale si comportano come ci si aspetterebbe se il test misurasse davvero quel costrutto: lo si vede sia dalla struttura interna del test sia dalle sue relazioni con altre variabili. La **validità di criterio** chiede se il test si associa a un outcome osservabile, il *gold standard*. In chiusura vediamo due etichette particolari: la **validità di facciata**, un concetto storico che riguarda quanto il test *sembra* misurare ciò che dichiara, e la **validità ecologica**, che riguarda i comportamenti nella vita quotidiana.

Per un approfondimento sulle classificazioni più classiche si veda Urbina (2004).

2 Validità di contenuto

Definizione: validità di contenuto

La **validità di contenuto** è la proprietà degli item di essere sufficienti e adeguati per valutare il costrutto di interesse.

Un modo per quantificarla è il metodo di Lawshe (1975), che permette di ottenere una misura di validità di contenuto sia per i singoli item sia per il test nel suo complesso. Il metodo si articola in tre passaggi, a cui se ne può aggiungere un quarto opzionale.

Passo 1. Si chiede a un gruppo di esperti (i *panelist*) di valutare ciascun item, classificandolo come *essenziale*, *utile ma non essenziale* oppure *non necessario*.

Passo 2. Per ogni item si calcola un *Content Validity Ratio* (CVR).

Definizione: Content Validity Ratio (CVR)

$$CVR = \frac{n_e - \frac{N}{2}}{\frac{N}{2}}$$

dove n_e è il numero di panelist (cioè di esperti) che giudicano l'item essenziale e N è il numero totale di panelist. Il CVR varia da -1 a 1 e vale 0 quando esattamente metà dei panelist giudica l'item essenziale. **Il CVR si riferisce a ciascun item, non al test.**

Per comodità e per convenzione, ogni valore pari a 1 viene aggiustato a 0.99.

Passo 3. Si selezionano gli item da mantenere. Ma quali? Lawshe fornisce una tabella di valori critici di CVR (Figura 1); in alternativa, si mantengono gli item con CVR ≥ 0.78 (Polit, Beck, & Owen, 2007).

Passo 4 (opzionale). Dai CVR dei singoli item si può passare a un valore riferito all'intero test, il *Content Validity Index* (CVI).

Definizione: Content Validity Index (CVI)

Il CVI è la **media** dei CVR di tutti gli item del test:

$$CVI = \frac{\sum_{I_1}^{I_k} \left(\frac{n_e - \frac{N}{2}}{\frac{N}{2}} \right)}{k}$$

dove, oltre a n_e e N già definiti, k è il numero degli item e I indica gli item che compongono il test.

2.1 Note sul metodo di Lawshe

È interessante notare che il metodo risponde solo in parte alla domanda sulla validità di contenuto. Il metodo di Lawshe dice se un dato item è appropriato per il test, ma non se il test contiene tutti

N. di panelist	Valore minimo di CVR
5	.99
6	.99
7	.99
8	.75
9	.78
10	.62
11	.59
12	.56
13	.54
14	.51
15	.49
20	.42
25	.37
30	.33
35	.31
40	.29

Figura 1: Tabella del metodo di Lawshe (1975) per la selezione degli item.

gli item necessari per i suoi scopi. Nell'articolo originale, infatti, Lawshe discute alcuni esempi in cui gli item di partenza sono già stati definiti e il problema è stabilire se siano appropriati.

Va detto infine che la validità di contenuto spesso non è considerata né riportata nei test (non è molto di moda).

C'è poi un limite più generale: il metodo di Lawshe si basa interamente sul giudizio degli esperti. Ci dice se gli item *sembrano appropriati* a chi conosce il costrutto, ma non come gli item si comportano quando il test viene somministrato, né se misurano davvero il costrutto. Per rispondere a queste domande bisogna guardare ai dati: è il terreno della validità di costrutto.

3 Validità di costrutto

Definizione: validità di costrutto

La **validità di costrutto** esprime quanto il test misura effettivamente il costrutto che intende misurare, valutando la coerenza interna degli item oppure la correlazione con altri test.

3.1 Due livelli, due fonti di evidenza

La validità di costrutto può essere valutata in due maniere: verificando se gli **item** misurano in maniera appropriata il costrutto, oppure verificando se il **punteggio totale del test**[1] misura in maniera appropriata il costrutto, cioè se lo rappresenta correttamente.

Questi due livelli corrispondono, secondo gli *Standards*, a **due fonti di evidenza distinte**. Il livello degli item riguarda la **struttura interna** del test, e si indaga con la consistenza interna, l'analisi fattoriale e la PCA. Il livello del punteggio totale riguarda le **relazioni con altre variabili**, e si indaga soprattutto con la correlazione. Per comodità, e come avviene nei manuali dei test neuropsicologici, qui entrambe restano sotto l'etichetta classica di "validità di costrutto". Le sottosezioni che seguono rispettano questo ordine: prima la struttura interna, poi le relazioni con altri test.

3.2 Consistenza interna

Uno dei modi classici per vedere se tutti gli item di un test si comportano in maniera coerente è valutarne la consistenza interna, tramite metriche come l'alpha di Cronbach. Questa, però, è spesso associata più all'affidabilità, e per questo è trattata nella lezione sulle formule dell'affidabilità.

La consistenza interna ci dice se gli item sono coerenti *nel complesso*; per capire *come* gli item si raggruppano, e attorno a quali variabili latenti, si usa l'analisi fattoriale.

3.3 Analisi fattoriale

L'analisi fattoriale è l'analisi statistica più comunemente utilizzata per valutare gli item.

> Definizione: analisi fattoriale
>
> Nel contesto della teoria dei test, l'**analisi fattoriale** indaga se gli item di un test si comportano in maniera coerente, dimostrando che misurano una stessa variabile latente (detta **fattore**).

Operativamente, e per questi scopi, l'analisi viene condotta su una matrice $m \times n$, in cui (come nella figura) i partecipanti sono in riga e gli item in colonna.

	i_1	i_2	i_3	i_4	...	i_n
p_1	x_{11}	x_{12}	x_{13}	x_{14}	...	x_{1n}
p_2	x_{21}	x_{22}	x_{23}	x_{24}	...	x_{2n}
p_3	x_{31}	x_{32}	x_{33}	x_{34}	...	x_{3n}
p_4	x_{41}	x_{42}	x_{43}	x_{44}	...	x_{4n}
...	...	...	...	...	...	...
p_m	x_{m1}	x_{m2}	x_{m3}	x_{m4}	...	x_{mn}

Figura 2: Matrice dei dati per l'analisi fattoriale: partecipanti (p) in riga, item (i) in colonna.

[1] Nella maggior parte dei casi il punteggio totale si ottiene sommando gli item (in alcuni casi facendone la media).

Il risultato di un'analisi fattoriale è spesso una matrice di *loadings*.

> Definizione: loading
>
> Il **loading** (l) indica quanto ciascun item (i) è correlato con un determinato fattore (F).

Esistono delle *rule of thumb* per stabilire se un loading è significativo, ad esempio valori maggiori di 0.3 o 0.5 (oppure minori di -0.3 o -0.5).

	f_1	f_2	f_3
i_1	l_{11}	l_{12}	l_{13}
i_2	l_{21}	l_{22}	l_{23}
i_3	l_{31}	l_{32}	l_{33}
i_4	l_{41}	l_{42}	l_{43}
...	...	...	...
i_n	l_{n1}	l_{n2}	l_{n3}

Figura 3: Matrice dei loadings: i = item, F = fattore, l = loading.

Vediamo due esempi in cui gli item caricano su due fattori. Nel primo, un fattore cattura una correlazione positiva tra gli item 1, 2 e 3, che tendono ad avere punteggi correlati tra loro; il secondo fattore cattura una correlazione positiva tra gli item 4 e 5, anch'essi con punteggi correlati tra loro. È uno scenario ideale, in cui gli item "caricano" chiaramente e in maniera distinta su specifici fattori.

	f_1	f_2
i_1	0.2	0.03
i_2	0.5	-0.04
i_3	0.7	0
i_4	0.01	0.8
i_5	0.05	0.9

Figura 4: Primo esempio: scenario ideale, con item che caricano in modo distinto su due fattori.

Nel secondo esempio, il primo fattore cattura una correlazione positiva tra gli item 2, 3, 4 e 5, che tendono ad avere punteggi tutti correlati tra loro. Il secondo fattore cattura invece una correlazione negativa degli item 1 e 4 rispetto all'item 5: in sostanza, quando i punteggi degli item 1 e 4 sono alti, quelli dell'item 5 sono bassi, e viceversa. Questo è uno scenario più complesso (e più comune):

il fatto che un item carichi su più fattori (*cross-loadings*) può indicare che l'item non è adeguato o che il modello teorico va rivisto.

	f_1	f_2
i_1	0.2	0.7
i_2	0.5	-0.04
i_3	0.7	0
i_4	0.9	0.8
i_5	0.7	- 0.9

Figura 5: Secondo esempio: scenario più complesso, con cross-loadings.

Esistono due tipi principali di analisi fattoriale, che si distinguono per lo scopo.

Definizione: analisi fattoriale esplorativa e confermativa

L'**analisi fattoriale esplorativa** ha lo scopo di definire quale struttura fattoriale descriva meglio (se esiste) la relazione tra gli item. L'**analisi fattoriale confermativa** ha lo scopo di verificare se gli item si comportano in maniera conforme a una struttura fattoriale nota.

Nel contesto della validità di costrutto, l'analisi fattoriale può essere usata per selezionare gli item che comporranno il test finale, ad esempio escludendo quelli che non si comportano in maniera adeguata rispetto al costrutto (o ai costrutti) che si intendeva misurare. Se un test intende misurare un singolo costrutto e tutti gli item tranne uno hanno loading alti su un fattore, probabilmente quell'item andrebbe eliminato dalla versione finale del test.

Per valutare la bontà di un'analisi fattoriale esistono molte analisi statistiche e metriche. Tra le più comuni c'è il test di *Goodness-of-Fit* (un test che riporta un Chi-quadro), che deve risultare **non significativo** ($p > 0.05$): se è significativo, la struttura a fattori proposta non è sufficiente a spiegare la variabilità dei dati. Un'altra metrica è il **RMSEA** (*Root Mean Squared Error of Approximation*), che deve essere il più basso possibile; di solito un valore < 0.06 è considerato una soglia minima.

L'analisi fattoriale è spesso rappresentata graficamente, distinguendo i fattori latenti (qui rappresentati da cerchi) dalle variabili osservate (qui rappresentate da quadrati).

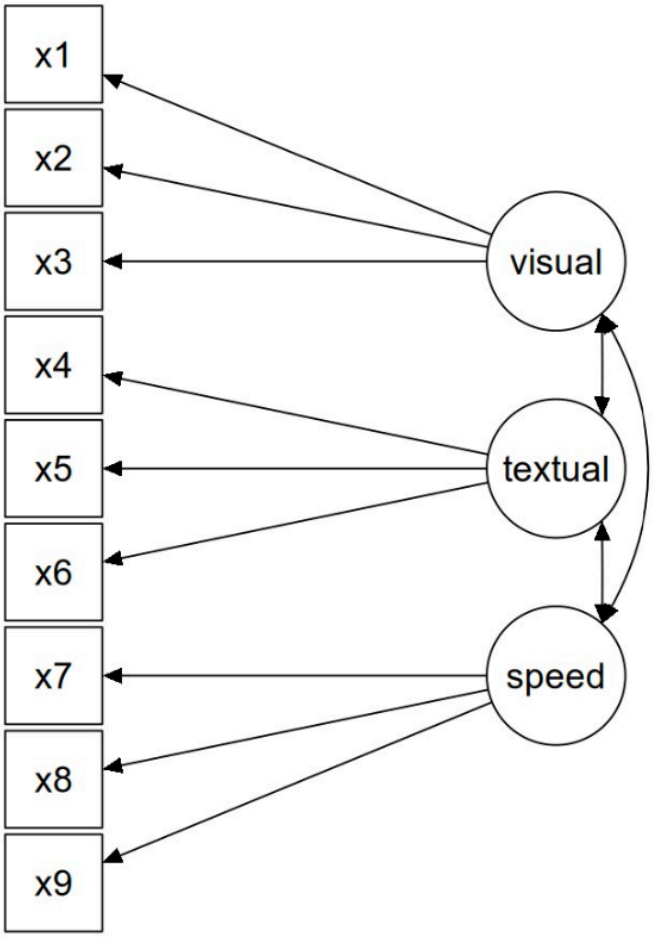


Figura 6: Rappresentazione grafica di un'analisi fattoriale. Fonte: https://lavaan.ugent.be/tutorial/cfa.html.

Per interpretare se un'analisi fattoriale supporta effettivamente la validità di costrutto, bisogna verificare se gli item si comportano davvero come il test assume che dovrebbero comportarsi. Ad esempio, se un test sostiene di misurare un costrutto specifico (come l'attenzione visuospaziale), tutti gli item dovrebbero caricare su un solo fattore (almeno principalmente). È innanzitutto utile vedere se gli autori del test hanno effettuato un'analisi fattoriale per indagare la relazione tra gli item e se li hanno selezionati di conseguenza (escludendone alcuni), o più in generale se c'è stata una qualche fase di selezione degli item (ad esempio tramite correlazione).

Stabilire l'adeguatezza di un'analisi fattoriale non è comunque semplice, perché spesso è possibile giustificare i risultati solo a posteriori, senza che questi abbiano influenzato la scelta di tenere o meno certi item. Potrei, ad esempio, avere un test che assume di misurare uno specifico costrutto, scoprire con un'analisi fattoriale esplorativa che in realtà la variabilità degli item è spiegata da *due* fattori, e mantenere comunque tutti gli item sostenendo che sono probabilmente influenzati da due fattori separati, coerenti con le aspettative teoriche (ad esempio attenzione visuospaziale e funzioni esecutive). Questo problema delle giustificazioni a posteriori tornerà anche con le correlazioni.

Si noti infine che a volte l'analisi fattoriale è applicata anche ai punteggi delle sottoscale che compongono una batteria, ad esempio per l'APACS (Arcara & Bambini, 2016). I principi sono gli stessi,

ma in questo caso le unità di analisi non sono singoli item bensì gruppi di item che compongono sottoscale (nell'esempio, il task di Linguaggio Figurato 1, il task di Linguaggio Figurato 2, e così via).

3.4 Principal Component Analysis (PCA)

Nei manuali dei test, al posto dell'analisi fattoriale si incontra spesso un'analisi concettualmente simile, la PCA.

> Definizione: Principal Component Analysis (PCA)
>
> La **PCA** ha lo scopo di *ottenere nuove variabili che catturano porzioni di varianza comune tra più punteggi* (ad esempio item, o punteggi totali di test). Queste nuove variabili sono dette **componenti principali**, da cui il nome dell'analisi.

Anche il risultato della PCA è una matrice di loadings, simile a quella dell'analisi fattoriale. La differenza è che nella PCA non si stimano "variabili latenti", e questo si riflette sia nella formula sia nei risultati che si ottengono.

Potreste quindi trovare, nella documentazione di un test, una PCA invece di un'analisi fattoriale. Le due si possono interpretare in maniera analoga, anche se sarebbe più corretto usare l'analisi fattoriale, perché assume l'esistenza di variabili latenti, cosa spesso implicita quando si tratta di item o di punteggi totali di test psicologici.

3.5 Una nota su analisi fattoriale e PCA

Analisi fattoriale e PCA ci aiutano a capire come si raggruppano gli item e se lo fanno in maniera coerente con il costrutto (o i costrutti) che dovrebbero misurare. Non garantiscono però che il costrutto sia quello giusto, e pertanto forniscono solo un'informazione parziale sulla validità.

Immaginiamo di voler valutare la validità di costrutto di un test di memoria. Gli autori potrebbero riportare un'analisi fattoriale che mostra che gli item correlano bene fra loro e sono riconducibili a un'unica variabile latente. Questo è ottimo, ma *non garantisce che quella variabile latente sia effettivamente la memoria*: il test potrebbe essere stato costruito in maniera sbagliata, e gli item potrebbero essere consistenti per un altro motivo (ad esempio perché il test cattura soprattutto la velocità psicomotoria).

Per capire *che cosa* il test stia misurando, la struttura interna non basta: bisogna guardare fuori dal test, cioè a come il suo punteggio si relaziona con altri test. È la seconda fonte di evidenza, che si indaga con la correlazione.

3.6 Correlazione

Lo strumento più comune per verificare la validità di costrutto di un test è indagare la correlazione tra il suo punteggio totale e i punteggi ottenuti ad altri test.

Non esiste una soglia universale (il libro è chiaro su questo, vedi Arcara, 2025): ciò che conta è che la correlazione con test dello stesso costrutto sia più alta di quella con test di costrutti diversi. Come

regola pratica è ragionevole aspettarsi che sia almeno moderata (> 0.3), ma verosimilmente anche di più. I test neuropsicologici, specie nelle persone sane, tendono infatti a essere **molto correlati fra loro**, e ci si attendono quindi correlazioni più alte; di fatto, sono proprio queste correlazioni ad aver portato a ipotizzare il cosiddetto fattore *g* dell'intelligenza (https://en.wikipedia.org/wiki/G_factor_(psychometrics)).

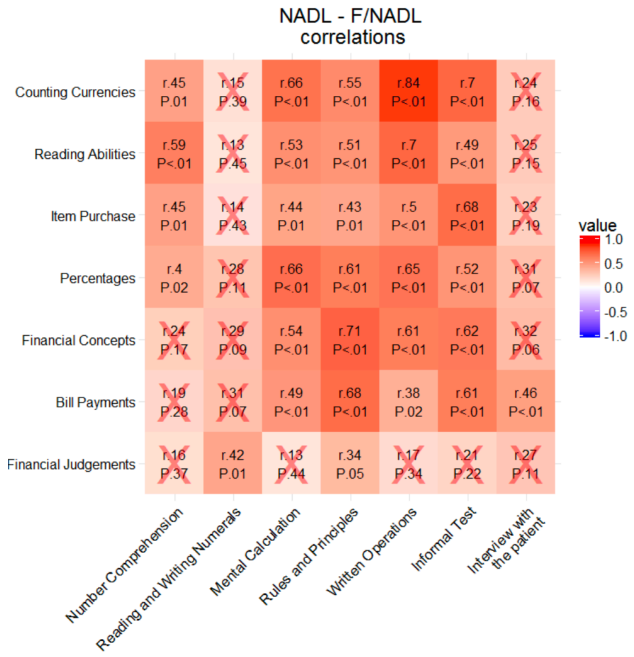


Figura 7: Correlazioni tra alcuni test del NADL (Semenza et al., 2014) e il NADL-F (Arcara et al., 2019).

L'aspetto critico nell'interpretare valori "soglia" di correlazione tra due test diversi è che questi valori dipendono anche dagli errori dei rispettivi test, e quindi da aspetti legati alla numerosità campionaria e all'affidabilità (temi ripresi nelle lezioni successive). Inoltre, come già per l'analisi fattoriale, è sempre possibile "giustificare" a posteriori una differenza o un valore basso (ad esempio: "la correlazione è bassa presumibilmente perché questo test coinvolge più dell'altro le funzioni esecutive").

Anche l'assenza di correlazione, o una correlazione molto bassa, può essere usata a sostegno di una buona validità di costrutto. In generale la validità di costrutto indica quanto bene stiamo misurando lo specifico costrutto, e dimostrare che stiamo isolando bene la specifica funzione cognitiva va a sostegno della validità di costrutto.

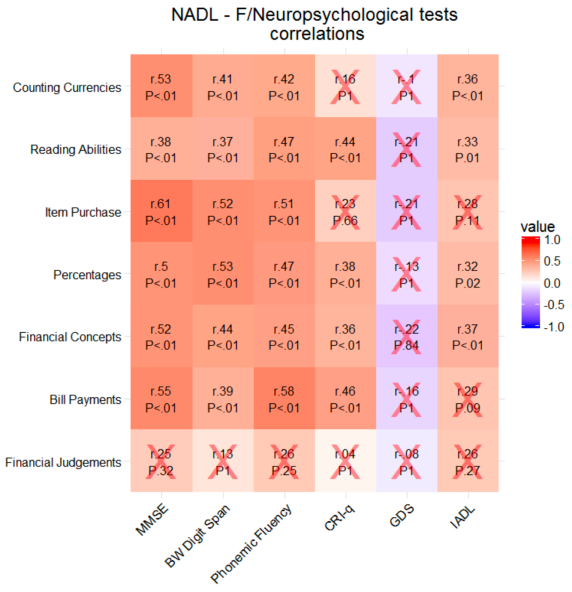


Figura 8: Correlazioni tra test di vario tipo e il NADL-F (Arcara et al., 2019). Il NADL-F non correla con la GDS (Geriatric Depression Scale), a sostegno della sua validità di costrutto.

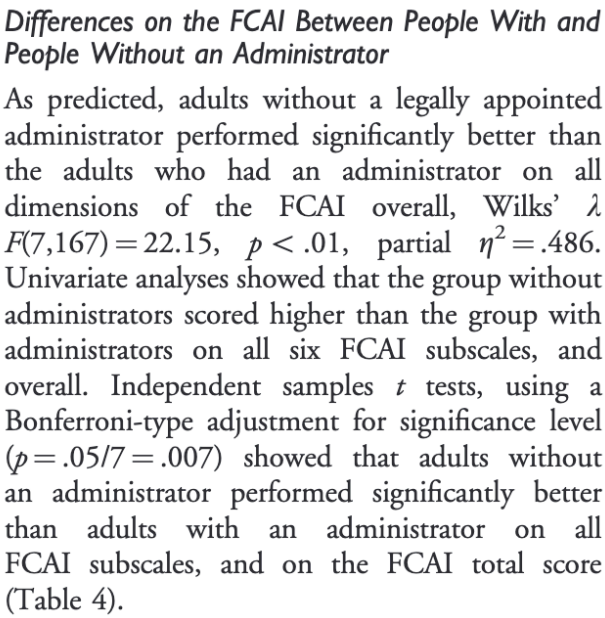
3.7 Altre analisi

Analisi fattoriale e correlazione sono gli strumenti più comuni, ma abbiamo visto che entrambe lasciano spazio a interpretazioni a posteriori. In generale, la validità di costrutto non è vincolata a specifiche analisi statistiche e andrebbe valutata rispetto alla specifica domanda a cui cerca di rispondere. In altre parole, piuttosto che cercare nei manuali o negli articoli specifiche analisi ("è stata fatta un'analisi fattoriale? ci sono correlazioni?"), dovreste cercare di rispondere a questa domanda:

> *Esistono evidenze sperimentali che suggeriscono che il test stia misurando quello che intende misurare?*

Ad esempio, un test che ha come obiettivo valutare la capacità di lavorare potrebbe non avere alcuna correlazione con altri test, ma essere buono nel discriminare le persone che sono state licenziate da quelle che hanno mantenuto il lavoro (in questo caso con una regressione logistica o con altre analisi più legate alla discriminazione).

Un esempio reale viene da Kershaw & Webber (2008). Il FCAI è un test per la valutazione delle competenze finanziarie; per dimostrarne la validità di costrutto, gli autori hanno confrontato (tramite MANOVA) partecipanti con e senza tutore legale.



Differences on the FCAI Between People With and People Without an Administrator

As predicted, adults without a legally appointed administrator performed significantly better than the adults who had an administrator on all dimensions of the FCAI overall, Wilks' λ $F(7,167) = 22.15$, $p < .01$, partial $\eta^2 = .486$. Univariate analyses showed that the group without administrators scored higher than the group with administrators on all six FCAI subscales, and overall. Independent samples t tests, using a Bonferroni-type adjustment for significance level ($p = .05/7 = .007$) showed that adults without an administrator performed significantly better than adults with an administrator on all FCAI subscales, and on the FCAI total score (Table 4).

Figura 9: Esempio da Kershaw & Webber (2008): confronto al FCAI tra partecipanti con e senza tutore legale.

È anche possibile combinare le analisi viste finora per supportare la validità di costrutto. Ad esempio, Montemurro et al. (2023), per dimostrare che il test Tele-GEMS era utile per valutare la cognizione generale, hanno prima raccolto dati su vari test in pazienti (con Sclerosi Multipla, in quel caso); hanno poi condotto una PCA su questi test, ottenendo un punteggio globale (la prima componente) che catturava il 60% della varianza; infine hanno verificato se il punteggio al Tele-GEMS correlava con questo punteggio globale. La correlazione era 0.50 (moderata/alta) ed è stata interpretata a supporto di una buona validità di costrutto del test.

Un altro esempio, ipotetico, di come combinare le analisi: se l'analisi fattoriale mostra che gli item si comportano come se catturassero due variabili latenti, una associata all'attenzione e una alla memoria, sarebbe utile — e a supporto della validità di costrutto — che i punteggi ottenuti sommando queste due parti correlassero rispettivamente con un altro test di attenzione e con un altro test di memoria.

3.8 Una possibile soluzione alla flessibilità: la pre-registrazione

Tutti gli esempi precedenti mostrano quanta flessibilità ci sia nella scelta e nell'interpretazione delle analisi di validità di costrutto: un risultato inatteso, nell'analisi fattoriale come nelle correlazioni, può quasi sempre essere giustificato a posteriori. Un possibile modo per risolvere questo problema è *pre-registrare* le analisi e i risultati attesi per considerare buona la validità di costrutto (per approfondimenti: https://en.wikipedia.org/wiki/Preregistration_(science)). Si noti che la pre-registrazione risolve, *in generale*, i problemi di flessibilità o di scarsa chiarezza delle analisi.

4 Validità di criterio

Negli ultimi esempi (licenziati vs non licenziati, persone con e senza tutore legale) il test veniva confrontato con qualcosa di osservabile. Quando l'interesse principale è proprio questo legame con un outcome osservabile si parla di validità di criterio.

> Definizione: validità di criterio
>
> La **validità di criterio** valuta quanto un test è associato a, o predice, un'altra variabile di outcome (osservabile), detta **gold standard**.

Le analisi da utilizzare, e il modo di valutarne i risultati, cambiano a seconda che il criterio sia una variabile continua (ad esempio il punteggio a un altro test) oppure una variabile categoriale (ad esempio l'appartenenza a un gruppo, come MCI vs controlli).

La validità di criterio può essere distinta in concorrente o predittiva (si vedano le slide *Validità e affidabilità – teoria*), ma questa distinzione generalmente non cambia il modo in cui vengono condotte le analisi, che dipende solo dal fatto che il criterio sia una variabile continua o categoriale.

4.1 Criterio continuo

Se il gold standard è una variabile continua, la validità di criterio si può valutare tramite una correlazione, la stessa analisi vista per la validità di costrutto. Come riferimento indicativo, valori pari o superiori a 0.70–0.80 sono considerati elevati in molti contesti applicativi (non si tratta comunque di un requisito universale). A partire dalla correlazione si può calcolare la varianza spiegata (nota anche come r^2), che non è altro che il coefficiente di correlazione al quadrato.

A volte, per calcolare la validità di criterio, si usa la regressione lineare. Nel caso di due variabili la regressione lineare è strettamente imparentata con il coefficiente di correlazione (e infatti alcuni dei risultati sono matematicamente identici).

4.2 Criterio categoriale

Nel caso di variabili categoriali (ad esempio sopra/sotto cut-off, oppure MCI vs controlli) si utilizzano famiglie di analisi diverse.

> Definizione: condizione di interesse
>
> Quando il criterio è categoriale, la categoria più rilevante (spesso quella patologica) è detta **condizione di interesse**.

Per ora diciamo solo che, quando si confronta un test con il suo criterio categoriale, esistono quattro tipi di possibili risultati.

	Condition of interest		
	Present (e.g. examinee with a pathology)	Absent (e.g. healthy examinee)	Row Total
Positive test (defective performance)	True Positive (A)	False Positive (B)	A+B
Negative test (adequate performance)	False Negative (C)	True Negative (D)	C+D
Column Total	A+C	B+D	

Figura 10: I quattro possibili esiti del confronto tra un test e un criterio categoriale.

Tutte le metriche legate a questa tabella rientrano nei concetti di sensibilità e specificità, che saranno trattati in apposite lezioni (dopo i cut-off).

4.3 Validità di criterio o di costrutto?

Poiché la correlazione si usa sia per la validità di costrutto sia per quella di criterio, è utile chiedersi quale delle due etichette sia appropriata. Se l'interesse è misurare un costrutto psicologico (ad esempio memoria o attenzione), sarebbe più pertinente parlare di **validità di costrutto** e valutarla con i metodi discussi sopra: la misurazione riguarda infatti un concetto inosservabile (costrutto, contrapposto a un criterio osservabile: Cronbach & Meehl, 1955).

In ambito neuropsicologico e psicologico raramente il punteggio a un altro test va considerato un criterio, ma ci sono eccezioni comuni: quando si vuole mostrare che un test breve è equivalente a uno lungo o dispendioso (e allora quello lungo è il "criterio"), oppure quando si vuole mostrare che un test online è equivalente a uno in presenza (le valutazioni in presenza sono di norma considerate il gold standard).

5 Validità di facciata (nota storica)

Fin qui abbiamo visto evidenze quantitative. La validità di facciata è di natura diversa: non riguarda ciò che il test misura, ma ciò che *sembra* misurare.

> Definizione: validità di facciata
>
> La **validità di facciata** valuta quanto un test *sembra* misurare ciò che intende misurare.

Il termine non compare negli *Standards* e viene qui trattato come concetto storico, non come fonte tecnica di evidenza.



Spesso è valutata tramite domande ad hoc rivolte a esperti, o tramite un confronto con test gold standard esistenti, ma solo in modo qualitativo: a differenza del metodo di Lawshe, dove il giudizio degli esperti viene quantificato, qui non si arriva a un indice. Talvolta la validità di facciata è l'unica informazione disponibile su un test: non ci sono altre prove che il test misuri ciò che vuole misurare, se non il fatto che è costruito con item che plausibilmente misurano proprio quel costrutto.

5.1 Validità di facciata in ambito forense

La validità di facciata può essere importante per assicurarsi la collaborazione del paziente e, in contesto forense, anche perché persone che non sono psicologi (ad esempio il giudice) accettino le conclusioni tratte. I test per identificare potenziali simulatori, ovviamente, non devono avere validità di facciata: anzi, il loro scopo non dovrebbe essere evidente.

6 Validità ecologica

Come per la validità di criterio, anche nella validità ecologica l'interesse è per comportamenti osservabili; in questo caso, però, si tratta dei comportamenti che avvengono fuori dal setting di valutazione.

> Definizione: validità ecologica
>
> La **validità ecologica** valuta quanto un test è in grado di prevedere comportamenti al di fuori del setting di valutazione, cioè nella vita quotidiana.

Spesso è studiata tramite correlazioni con altre scale riferite a comportamenti della vita quotidiana: diversamente da molti test, qui l'interesse non è per i costrutti ma per *altri comportamenti*. Può essere valutata anche con altre analisi, purché mostrino che i punteggi al test sono associati al fenomeno di vita quotidiana di interesse.

Ad esempio, si potrebbe indagare la correlazione tra il punteggio a un test di funzioni esecutive e il numero di comportamenti antisociali mostrati da un paziente durante un ricovero, per supportare l'idea che le informazioni fornite dal test siano associate a comportamenti legati alle funzioni esecutive nella vita quotidiana.

In sintesi

Le diverse etichette viste in questo handout non sono validità separate, ma modi diversi di raccogliere evidenze a favore di un unico concetto di validità. Nessuna singola analisi, presa da sola, basta a stabilirla: la domanda da porsi resta sempre se esistano evidenze che il test misuri ciò che intende misurare.

Riferimenti

American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). *Standards for educational and psychological testing*. Washington, DC: American Educational Research Association.

Arcara, G. (2025). Oltre i punteggi: Elementi di psicometria e statistica per la neuropsicologia clinica (Versione 0.3.0). Recuperato da https://giorgioarcara.github.io/oip-book/

Arcara, G., & Bambini, V. (2016). A test for the assessment of pragmatic abilities and cognitive substrates (APACS): Normative data and psychometric properties. *Frontiers in Psychology*, *7*, 70. https://doi.org/10.3389/fpsyg.2016.00070

Arcara, G., Burgio, F., Benavides-Varela, S., Toffano, R., Gindri, P., Tonini, E., … Semenza, C. (2019). Numerical Activities of Daily Living – Financial (NADL-F): A tool for the assessment of financial capacities. *Neuropsychological Rehabilitation*, *29*(7), 1062–1084. https://doi.org/10.1080/09602011.2017.1359188

Cronbach, L. J., & Meehl, P. E. (1955). Construct validity in psychological tests. *Psychological Bulletin*, *52*(4), 281–302. https://doi.org/10.1037/h0040957

Kershaw, M. M., & Webber, L. S. (2008). Assessment of financial competence. *Psychiatry, Psychology and Law*, *15*(1), 40–55. https://doi.org/10.1080/13218710701873965

Lawshe, C. H. (1975). A quantitative approach to content validity. *Personnel Psychology*, *28*(4), 563–575. https://doi.org/10.1111/j.1744-6570.1975.tb01393.x

Montemurro, S., Mondini, S., Pucci, V., Durante, G., Riccardi, A., Maffezzini, S., … Arcara, G. (2023). Tele-Global Examination of Mental State (Tele-GEMS): An open tool for the remote neuropsychological screening. *Neurological Sciences*, *44*(10), 3499–3508. https://doi.org/10.1007/s10072-023-06862-1

Polit, D. F., Beck, C. T., & Owen, S. V. (2007). Is the CVI an acceptable indicator of content validity? Appraisal and recommendations. *Research in Nursing & Health*, *30*(4), 459–467. https://doi.org/10.1002/nur.20199

Semenza, C., Meneghello, F., Arcara, G., Burgio, F., Gnoato, F., Facchini, S., … Butterworth, B. (2014). A new clinical tool for assessing numerical abilities in neurological diseases: Numerical activities of daily living. *Frontiers in Aging Neuroscience*, *6*, 112. https://doi.org/10.3389/fnagi.2014.00112

Urbina, S. (2004). *Essentials of psychological testing*. Hoboken, NJ: John Wiley & Sons.