Affidabilità: formule e analisi

Handout della lezione 3c — Metodi Statistici per la Neuropsicologia Forense

Giorgio Arcara

Nota sull'uso dell'intelligenza artificiale

Questo handout è stato generato con l'assistenza di **Claude** (Anthropic), un modello di intelligenza artificiale, a partire dalle slide della lezione 3c (*Affidabilità – formule*) e usando come riferimento il libro del corso, *Oltre i punteggi* (Arcara, 2025). Al modello è stato chiesto di riscrivere in forma discorsiva il contenuto delle slide, integrandone le figure, **senza aggiungere nuovo materiale**. Il testo può comunque contenere imprecisioni: in caso di dubbio fanno fede le slide, il libro e quanto detto a lezione.

Materiale distribuito con licenza CC BY-NC 3.0, come le slide del corso.

1 Affidabilità/precisione

Definizione: affidabilità

L'**affidabilità** è la qualità di un test di fornire punteggi consistenti in diverse misurazioni; può essere intesa come la precisione di un test (Arcara, 2025).

Gli *Standards for Educational and Psychological Testing* (American Educational Research Association, American Psychological Association, & National Council on Measurement in Education, 2014) trattano l'affidabilità come un **principio unitario**, usando il termine ombrello *affidabilità/precisione*: non si tratta di un'unica proprietà, ma di un insieme di stime di precisione, ciascuna specifica a una **fonte di errore**. Le stime classiche sono tre, e ognuna guarda a una fonte di errore diversa: l'**affidabilità test-retest** riguarda il momento in cui il test viene somministrato, l'**inter-rater agreement** riguarda chi attribuisce il punteggio, la **consistenza interna** (con la sua versione più semplice, l'affidabilità split-half) riguarda gli item che compongono il test. L'handout le tratta in quest'ordine, per poi vedere come i diversi coefficienti si interpretano e si combinano a livello dell'intero test.

La terminologia usata è quella della Teoria Classica dei Test, il modello dominante per i test neuropsicologici; la *Generalizability Theory* e l'*Item Response Theory* usano termini diversi. Per le classificazioni si veda Urbina (2004).

1.1 Quanto deve essere alta l'affidabilità?

Non esistono soglie universali. Come riferimento orientativo, valido per tutti i tipi di affidabilità, si può usare la classificazione riportata da Slick (2006):

Tabella 1: Classificazione orientativa dei coefficienti di affidabilità (Slick, 2006).

Coefficiente	Interpretazione
≥ 0.90	molto alta
$0.80 - 0.89$	alta
$0.70 - 0.79$	adeguata
$0.60 - 0.69$	marginale
< 0.60	bassa

Per le **decisioni cliniche sul singolo individuo**, Sattler (2001; citato in Slick, 2006) raccomanda soglie più stringenti: almeno 0.80; per le decisioni ad alto impatto (per esempio la stima del QI o una diagnosi) 0.90 è il minimo, e 0.95 il valore ottimale. In pratica conviene adottare un approccio *comparativo*: scegliere, tra i test disponibili, quello con l'affidabilità migliore. Nelle sezioni che seguono, per ogni tipo di affidabilità sono riportate anche soglie indicative specifiche.

2 Affidabilità test-retest

Definizione: affidabilità test-retest

L'**affidabilità test-retest** è una misura della consistenza dei punteggi ottenuti quando lo stesso test viene somministrato alle stesse persone in due momenti diversi, assumendo che nell'intervallo tra le somministrazioni non si siano verificati cambiamenti reali nel costrutto misurato e che le condizioni di valutazione siano comparabili (Arcara, 2025).

Una formula molto diffusa per calcolarla, specie nei test in italiano, è la correlazione di Pearson:

$$r = \frac{\sum(x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i - \bar{y})^2}}$$

dove x_i e y_i sono i punteggi al test e al retest, e $\bar{x}$ e $\bar{y}$ le rispettive medie.

2.1 Test-retest ed effetti sistematici

Il coefficiente di correlazione esprime la *consistenza relativa* tra le due misurazioni, cioè quanto le persone mantengono lo stesso ordinamento nelle due occasioni. Non cattura però eventuali *effetti sistematici*: può essere molto alto anche quando i punteggi al retest sono sistematicamente più alti.

Definizione: effetto sistematico ed effetto pratica

Un **effetto sistematico** è una variazione non casuale nei punteggi tra test e retest, presente in ogni individuo. Nei test cognitivi l'effetto sistematico più comune è l'**effetto pratica**: l'etichetta che indica quei cambiamenti (spesso sistematici) che si osservano nella nuova somministrazione del test e che sono associati a una prestazione migliore.

Per capire perché la correlazione non vede gli effetti sistematici, immaginiamo che a ogni osservazione del retest si aggiunga una quantità fissa k. Ne consegue che anche la media del retest aumenta di k:

$$r = \frac{\sum(x_i - \bar{x})(y_i + k - (\bar{y} + k))}{\sqrt{\sum(x_i - \bar{x})^2 \sum(y_i + k - (\bar{y} + k))^2}}$$

Con semplice algebra le k si cancellano e si torna alla formula iniziale: un aumento sistematico non cambia il valore della correlazione (si vedano anche le slide sulla correlazione nell'Appendice sui concetti base di statistica).

Bisogna dunque fare attenzione all'uso e all'interpretazione dei valori di affidabilità test-retest quando sono calcolati con una correlazione. In questo caso il coefficiente andrebbe accompagnato dall'analisi dei cambiamenti sistematici tra la prima e la seconda valutazione: per esempio il confronto tra le medie (con un t-test) e l'esame della distribuzione delle differenze (ad esempio, Arcara & Bambini, 2016).

2.2 Perché il test-retest conta anche per una singola valutazione

Spesso si pensa, erroneamente, che l'affidabilità test-retest sia utile solo quando si effettuano misurazioni ripetute. Conviene invece immaginare una valutazione come una fotografia di una scena statica: l'affidabilità test-retest stima quanto è precisa la macchina fotografica. Con un test ad alta affidabilità non ci aspettiamo molte variazioni possibili da una misurazione all'altra; con un test a bassa affidabilità, invece, ce ne aspettiamo molte. La nostra fotografia sarà una stima "puntuale", ma potrebbe essere lontana da quello che consideriamo il punteggio vero (che, ricordiamo, è un'entità teorica).

La Figura 1 mostra questo concetto con due test, uno a bassa e uno ad alta affidabilità test-retest, e due singole misurazioni ipotetiche, m_a e m_b. Per ciascun test si fa una sola valutazione e non c'è alcun interesse a rivalutare nel tempo; eppure, con il test ad alta affidabilità il punteggio osservato dipende molto meno dalla specifica occasione di misurazione.

2.3 Dalla correlazione all'ICC

Perché si usa così spesso la correlazione di Pearson, se non è del tutto adeguata? Probabilmente per convenzione e per semplicità: tra l'altro r permette di esprimere facilmente la varianza condivisa tra le variabili, semplicemente calcolando r^2. Non è del tutto sbagliato, e può fornire un quadro abbastanza completo se è accompagnato da t-test che indaghino le differenze sistematiche.

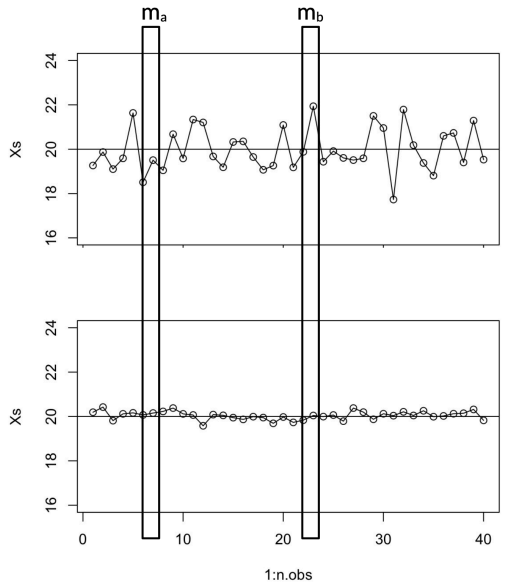


Figura 1: Due test con bassa (pannello in alto) e alta (pannello in basso) affidabilità test-retest. Le misurazioni m_a e m_b sono due possibili singole valutazioni: con il test a bassa affidabilità possono cadere lontano l'una dall'altra e dal valore centrale.

Esistono comunque altri modi di misurare l'affidabilità test-retest, e sempre più spesso si usano formule più appropriate, in particolare l'**Intraclass Correlation (ICC)** basata sull'*accordo assoluto*, che tiene conto anche degli effetti sistematici. Nel tipico disegno test-retest, con due occasioni prestabilite e uguali per tutti, si raccomanda un modello ICC a due vie, a effetti misti, basato sull'accordo assoluto e riferito a una singola misurazione, spesso indicato come ICC(2,1) o ICC(A,1) (Koo & Li, 2016; McGraw & Wong, 1996; Shrout & Fleiss, 1979).

Soglie indicative: non esiste una soglia universalmente valida. Un coefficiente pari o superiore a 0.70 viene talvolta considerato un requisito minimo per finalità di ricerca o per confronti tra gruppi. Quando il punteggio contribuisce a decisioni importanti sul singolo individuo sono generalmente richiesti valori più elevati: spesso almeno 0.90 e, idealmente, circa 0.95 (Nunnally & Bernstein, 1994).

Le formule dell'ICC sono presentate nella prossima sezione, dedicata all'inter-rater agreement, dove l'ICC è lo strumento principale.

3 Inter-rater agreement

Definizione: inter-rater agreement

L'**inter-rater agreement** (o *affidabilità inter-rater*) misura quanto è consistente il punteggio assegnato da valutatori diversi che osservano la stessa prestazione. È, praticamente per definizione, legato all'*oggettività* del test, cioè all'indipendenza del risultato dall'osservatore.

L'inter-rater agreement è tendenzialmente più basso nei test in cui la risposta non è univoca o è graduata (per esempio disegno, descrizione, interpretazione di proverbi), e più alto quando la

risposta corretta è univoca e dicotomica (per esempio il digit span). Al di là della complessità del comportamento da valutare, l'elemento cruciale e trasversale è la **chiarezza delle regole di attribuzione dei punteggi**, comprese le indicazioni su come comportarsi nei casi ambigui.

3.1 L'Intraclass Correlation (ICC)

La formula più utilizzata per l'inter-rater agreement è l'ICC. A differenza della correlazione, che mette in relazione solo due variabili, l'ICC può essere usata con k valutatori (*rater*).

> Definizione: Intraclass Correlation (ICC)
>
> L'**ICC** non è un singolo coefficiente ma una **famiglia** di coefficienti, che assumono relazioni diverse tra gruppi e osservazioni e si basano sulla scomposizione della varianza (ANOVA o modelli a effetti misti). Per l'inter-rater agreement sono rilevanti le ICC basate sull'**accordo assoluto**, che assumono valori alti solo se i valutatori assegnano più o meno lo stesso punteggio, e non solo se i loro punteggi sono correlati.

Per approfondire si può consultare la voce di Wikipedia (https://en.wikipedia.org/wiki/Intraclass_correlation).

Una versione spesso utilizzata è l'**ICC(2,1) agreement**, in cui si assume che diversi valutatori osservino la stessa prestazione dello stesso soggetto e si ottiene una stima dell'accordo in termini assoluti:

$$ICC(2,1) = \frac{MSB - MSE}{MSB + (n_j - 1)MSE + \frac{n_j(MSJ - MSE)}{n_c}}$$

dove MSB e MSJ sono la varianza tra soggetti e la varianza tra giudici (*rater*), MSE è la varianza dell'interazione giudici $\times$ soggetti, n_j è il numero di giudici e n_c il numero di casi.

La figura mostra come relazioni diverse tra due misurazioni vengano catturate da coefficienti diversi. Si noti che R^2 è il coefficiente di correlazione r elevato al quadrato, ma è anche usato nelle regressioni (in breve, analisi statistiche in cui si indaga la relazione tra variabili usando equazioni del tipo $y = bx + e$). Nel secondo e nel terzo pannello R^2 e le ICC di consistenza restano alte, mentre le ICC di accordo si abbassano.

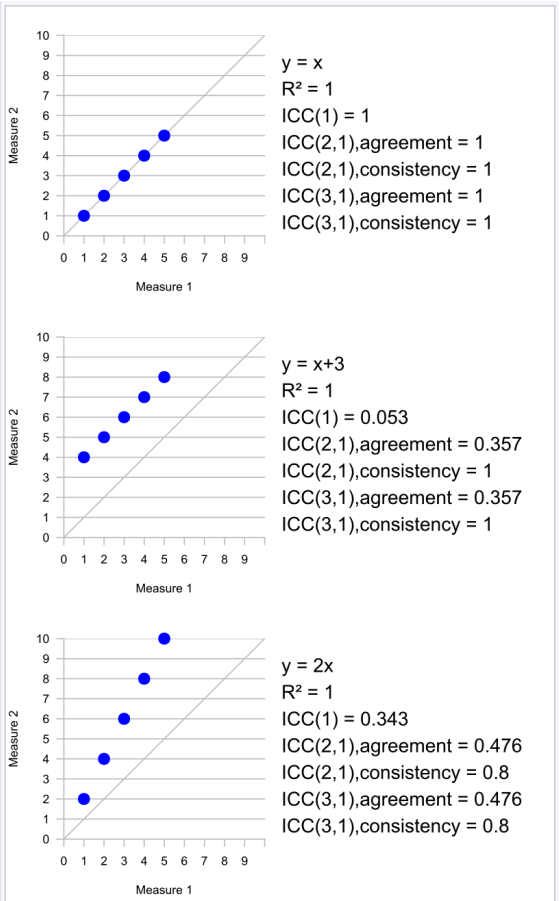


Figura 2: Diverse definizioni di ICC applicate a tre scenari di concordanza tra due misurazioni. Fonte: Wikipedia, voce *Intraclass correlation*.

3.2 Alcune considerazioni sull'ICC

Se l'ICC tiene conto anche delle differenze sistematiche, perché non viene sempre usata anche per il test-retest? Probabilmente per prassi e convenzione, che si osservano soprattutto nei test in italiano. In letteratura si trovano comunque studi che la usano anche per il test-retest, e nel corso degli anni sempre più autori adottano questa formula più appropriata: in presenza di effetto pratica sarebbe infatti più adeguata.

Soglie indicative per l'inter-rater agreement (ICC): secondo Cicchetti e Sparrow (1981; citati in Slick, 2006) valori inferiori a 0.40 sono scarsi, tra 0.40 e 0.59 discreti, tra 0.60 e 0.74 buoni, pari o superiori a 0.75 eccellenti. Con una classificazione simile, Fastenau, Bennett, & Denburg (1996) considerano 0.60 la soglia per un accordo "sostanziale" e 0.75–0.80 per un accordo "quasi perfetto".

Dopo il momento della somministrazione e il valutatore, resta la terza fonte di errore: gli item che compongono il test.

4 Split-half e consistenza interna

4.1 Affidabilità split-half

Definizione: affidabilità split-half

L'**affidabilità split-half** indica la consistenza di un test quando si confronta il punteggio totale ottenuto da metà degli item con il punteggio totale ottenuto con la rimanente metà degli item (Arcara, 2025).

Un approccio tradizionale per valutare la consistenza degli item di un test è dividerlo in due (tipicamente gli item pari da un lato e i dispari dall'altro) e calcolare, sui partecipanti, la correlazione tra i punteggi delle due metà. Poiché ciascuna metà è più corta dell'intero test, questa correlazione **sottostima** l'affidabilità del test completo: si applica quindi la correzione di **Spearman-Brown**.

Il limite principale è che il risultato dipende, almeno in parte, da come si divide il test. Per questo si preferisce la sua estensione, la consistenza interna. *Soglia indicativa*: pari o superiore a 0.70–0.80 (Slick, 2006).

4.2 Consistenza interna

Definizione: consistenza interna

La **consistenza interna** misura quanto gli item di un test siano tra loro coerenti, cioè quanto misurino, almeno in parte, la stessa cosa (Arcara, 2025).

Concettualmente, la consistenza interna stima quale sarebbe la correlazione media considerando *tutte* le possibili divisioni split-half. È un concetto a cavallo tra affidabilità e validità, perché riguarda anche la struttura fattoriale del test (si veda l'handout sulle formule della validità).

Esistono diverse formule per calcolarla. La formula di Kuder-Richardson (KR-20) si usa quando gli item sono dicotomici (0/1); l'alpha di Cronbach è l'indice più diffuso, e generalizza la KR-20 al caso di item non dicotomici.

Definizione: formula di Kuder-Richardson (KR-20)

$$r_{KR20} = \left(\frac{n}{n-1}\right) \frac{s_t^2 - \sum pq}{s_t^2}$$

dove n è il numero di item del test, s_t^2 la varianza del punteggio totale, $\sum pq$ la somma, su tutti gli item, del prodotto $p \times q$; p è la proporzione di persone che superano l'item (o rispondono 1) e q la proporzione di persone che non lo superano (o rispondono 0).

Definizione: alpha di Cronbach

$$\alpha = \left(\frac{n}{n-1}\right) \frac{s_t^2 - \sum s_i^2}{s_t^2}$$

dove n è il numero di item del test, s_t^2 la varianza del punteggio totale e s_i^2 la varianza di ciascun item.

L'alpha è un *limite inferiore* dell'affidabilità e assume item (essenzialmente) tau-equivalenti e unidimensionali.

4.3 Altri metodi per calcolare la consistenza interna

Sebbene KR-20 e alpha siano i più comuni, hanno limiti intrinseci, per esempio l'assunzione di unidimensionalità. Per questo esistono alternative. L'**omega di McDonald** (ω) è un'alternativa più recente e considerata **più robusta**, adatta anche in caso di multidimensionalità, e oggi spesso raccomandata come scelta di default. Il **GLB** (*Greatest Lower Bound*) è preferibile se i punteggi degli item non sono distribuiti normalmente. Omega e GLB sono legati all'analisi fattoriale (si vedano le slide sulla validità) e sono computazionalmente più complessi. Per i **test di velocità** la consistenza interna non è una misura appropriata.

Soglie indicative: valori inferiori a 0.70 sono considerati inaccettabili, tra 0.70 e 0.79 discreti, tra 0.80 e 0.89 buoni, pari o superiori a 0.90 eccellenti (Slick, 2006); nei test neuropsicologici la consistenza interna è però spesso intorno a 0.60.

4.4 Item selection

Alla consistenza interna è associato il concetto di **item selection**: la procedura con cui, nella costruzione di un test, si identificano gli item da mantenere nella versione finale. Alcune misure sono specifiche per i singoli item, un po' come i loadings nell'analisi fattoriale. Due esempi derivano dall'alpha di Cronbach.

Definizione: r-drop e r-cor

L'**r-drop** indica la correlazione tra il test e il test privato di quell'item: si ha quindi un valore di r-drop per ogni item. L'**r-cor** indica la correlazione tra l'item e il test totale, controllando per la sovrapposizione con gli altri item e per l'affidabilità globale.

5 Interpretare l'affidabilità a livello del test

Abbiamo visto coefficienti diversi, calcolati con formule diverse (r di Pearson, ICC(2,1), alpha, ecc.), per fonti di errore diverse. Tutti, però, condividono la stessa idea di fondo e si possono interpretare allo stesso modo.

Definizione: coefficiente di affidabilità

Ogni coefficiente di affidabilità stima la varianza riconducibile al punteggio vero rispetto alla variabilità totale, cioè quella che si rileva nei punteggi osservati:

$$r_{xx} = \frac{\sigma^2_{true}}{\sigma^2_{tot}}$$

Per questo motivo ogni coefficiente, indipendentemente dalla formula, può essere letto come la percentuale di variabilità riconducibile al punteggio vero, trasformandolo semplicemente in percentuale. Una correlazione test-retest di 0.8 significa che l'80% della variabilità test-retest è riconducibile alla variabilità del punteggio vero; una consistenza interna di 0.9 significa che il 90% della variabilità nella consistenza interna è riconducibile alla variabilità del punteggio vero, e così via.

Di conseguenza, l'errore associato a ogni fonte di affidabilità è calcolabile come:

$$Errore = (1 - C_a) \times 100$$

dove C_a è il coefficiente di affidabilità in questione (per esempio test-retest o inter-rater).

5.1 Combinare diversi tipi di errore

Calcolando l'errore per diverse fonti, è possibile sommarle (assumendo che siano indipendenti) per ottenere un errore totale, e quindi la parte di variabilità del punteggio che si presume riconducibile al punteggio vero. Supponiamo di avere un test con un'affidabilità test-retest di 0.85 (r di Pearson), un'affidabilità inter-rater di 0.70 (ICC(2,1)) e una consistenza interna di 0.97 (alpha di Cronbach). Gli errori sono:

- test-retest: $(1 - 0.85) \times 100 = 15\%$;
- inter-rater: $(1 - 0.70) \times 100 = 30\%$;
- consistenza interna: $(1 - 0.97) \times 100 = 3\%$;

per un errore totale di $15 + 30 + 3 = 48\%$. A livello del test, quindi, il 48% della varianza è riconducibile all'errore e il 52% ($100-48$) al punteggio vero; quest'ultimo valore è anche l'affidabilità complessiva del test (per un esempio simile si veda Urbina, 2004).

Attenzione: questa scomposizione additiva assume che le fonti di errore siano *indipendenti* ed è un artificio grossolano. Nella pratica psicometrica la precisione complessiva si esprime più propriamente con l'errore standard di misurazione (*SEM*) e con i relativi intervalli di confidenza, che qui non approfondiamo.

5.2 Affidabilità ed errore

In questo approccio, più informazioni abbiamo sulle diverse fonti di errore, più bassa risulta la percentuale riconducibile alla varianza del punteggio vero. Detto altrimenti, stimare la varianza riconducibile al punteggio vero a partire da un solo indice porta inevitabilmente a sovrastimarla.

6 Stimare il punteggio vero

Le formule di affidabilità permettono anche di stimare il punteggio vero:

$$T' = r_{xx}(X - M) + M$$

dove T' è la stima del punteggio vero, r_{xx} l'affidabilità complessiva (vedi la sezione precedente), X il punteggio osservato e M la media del campione di riferimento.

Su questa formula valgono tre note. La prima: la stima del punteggio vero è spesso accompagnata da intervalli di confidenza attorno alla stima (un tema che riprenderemo parlando di cut-off; si veda anche l'Appendice).

La seconda: nella formula la media del campione di riferimento (M) entra due volte. Questo permette di tenere conto di un fenomeno noto come regressione verso la media.

> Definizione: regressione verso la media
>
> In ogni misura affetta da errore è sempre più probabile che una misura successiva sia più vicina alla media del campione di riferimento. Questo accade perché, specie se l'errore dello strumento è grande, ogni deviazione dalla media ha una certa probabilità di essere dovuta al caso.

Correggere per la media ha però un grosso limite intrinseco: con quale media correggere? Per esempio, se valutiamo un paziente con trauma cranico (TBI), è corretto usare come M la media del gruppo di persone sane con cui è stato sviluppato il test?

La terza: limiti di questo tipo rendono complessa l'applicazione delle formule per stimare il punteggio vero. Come vedremo negli utilizzi clinici e pratici (per esempio cut-off e valori di cambiamento), **quasi sempre non si usano i punteggi veri ma i punteggi osservati**.

In sintesi

L'affidabilità non è una proprietà unica: ogni coefficiente stima la precisione del test rispetto a una specifica fonte di errore (momento della somministrazione, valutatore, item), e tutti si possono leggere come quota di varianza riconducibile al punteggio vero. Le soglie sono solo indicative: nella scelta di un test conviene un approccio comparativo, tenendo presente che per le decisioni sul singolo individuo servono valori più alti.

Riferimenti

American Educational Research Association, American Psychological Association, & National Council on Measurement in Education. (2014). *Standards for educational and psychological testing*. Washington, DC: American Educational Research Association.

Arcara, G. (2025). Oltre i punteggi: Elementi di psicometria e statistica per la neuropsicologia clinica (Versione 0.3.0). Recuperato da https://giorgioarcara.github.io/oip-book/

Arcara, G., & Bambini, V. (2016). A test for the assessment of pragmatic abilities and cognitive substrates (APACS): Normative data and psychometric properties. *Frontiers in Psychology*, *7*, 70. https://doi.org/10.3389/fpsyg.2016.00070

Cicchetti, D. V., & Sparrow, S. S. (1981). Developing criteria for establishing interrater reliability of specific items: Applications to assessment of adaptive behavior. *American Journal of Mental Deficiency*, *86*(2), 127–137.

Fastenau, P. S., Bennett, J. M., & Denburg, N. L. (1996). Application of psychometric standards to scoring system evaluation: Is «new» necessarily «improved»? *Journal of Clinical and Experimental Neuropsychology*, *18*(3), 462–472. https://doi.org/10.1080/01688639608409003

Koo, T. K., & Li, M. Y. (2016). A guideline of selecting and reporting intraclass correlation coefficients for reliability research. *Journal of Chiropractic Medicine*, *15*(2), 155–163. https://doi.org/10.1016/j.jcm.2016.02.012

McGraw, K. O., & Wong, S. P. (1996). Forming inferences about some intraclass correlation coefficients. *Psychological Methods*, *1*(1), 30–46. https://doi.org/10.1037/1082-989X.1.1.30

Nunnally, J. C., & Bernstein, I. H. (1994). *Psychometric theory* (3ª ed.). New York: McGraw-Hill.

Sattler, J. M. (2001). *Assessment of children: Cognitive applications* (4ª ed.). San Diego, CA: Jerome M. Sattler.

Shrout, P. E., & Fleiss, J. L. (1979). Intraclass correlations: Uses in assessing rater reliability. *Psychological Bulletin*, *86*(2), 420–428. https://doi.org/10.1037/0033-2909.86.2.420

Slick, D. J. (2006). Psychometrics in neuropsychological assessment. In E. Strauss, E. M. S. Sherman, & O. Spreen, *A compendium of neuropsychological tests: Administration, norms, and commentary* (3ª ed.). New York: Oxford University Press.

Urbina, S. (2004). *Essentials of psychological testing*. Hoboken, NJ: John Wiley & Sons.